Analyse statistique des attributs des chansons sur Spotify

Étude de la popularité

Réalisé par :
Ammar HADDAD
Anas SABBAHI
Othmane Tahfi

Encadré par :
Lahcen DOUGE
Mohammed EL MACHKOURI

12 mai 2025

Table des matières

1 Introduction **2**

2 Chargement et exploration du dataset **2**
2.1 Aperçu global . . . 2
2.1.1 Forme du Dataset . . . 2
2.1.2 Valeurs Manquantes . . . 3
2.1.3 Types de Données . . . 3

3 Visualisations exploratoires **4**
3.1 Distribution de la variable cible . . . 4
3.2 Heatmap des corrélations . . . 5
3.2.1 Corrélations les plus fortes (positives) . . . 5
3.2.2 Corrélations les plus fortes (négatives) . . . 5
3.2.3 Corrélation avec la variable "target" . . . 6
3.3 Pairplots . . . 6
3.4 Histograms des attributs . . . 7
3.5 Analyse des caractéristiques audio (en lien avec le target) . . . 9

4 Analyse statistique **10**
4.1 Test du Chi² (vs target) . . . 10
4.2 ANOVA . . . 10

5 Préparation des données **11**
5.1 Variables retenues . . . 11
5.2 Normalisation . . . 11
5.3 . . . 12
5.3.1 Colonnes normalisées avec `StandardScaler` . . . 12
5.3.2 Colonnes transformées avec `RobustScaler` . . . 12
5.4 Encodage . . . 13
5.5 Splitting . . . 13

6 Modélisation et évaluation **13**

7 Tuning **14**

8 Modèle final **15**

9 Synthèse **15**
9.1 Perspectives . . . 15

Introduction

La popularité d'une chanson est un phénomène complexe influencé par divers facteurs musicaux et contextuels. Grâce aux vastes quantités de données collectées par Spotify, il est possible d'analyser les attributs des chansons afin de mieux comprendre les éléments qui contribuent à leur succès.

Ce projet vise à explorer les relations entre différents attributs musicaux (tempo, danseabilité, énergie, tonalité, etc.) et la popularité des chansons. L'analyse s'appuiera sur des statistiques descriptives, des visualisations graphiques et des modèles prédictifs.

L'objectif est d'identifier les caractéristiques clés qui influencent le plus la popularité des morceaux et d'évaluer la performance de modèles prédictifs dans ce contexte. Les résultats obtenus pourront offrir des insights pertinents pour les artistes, producteurs et plateformes de streaming souhaitant optimiser la diffusion et le succès de leur musique.

Chargement et exploration du dataset

Le tableau ci-dessous présente les variables utilisées dans l'analyse des chansons ainsi que leurs descriptions et types.

TABLE 1 – Description des variables

Nom de la variable	Description	Type
acousticness	Niveau d'acoustique d'une chanson (valeur entre 0 et 1)	Numérique (float)
danceability	Mesure de la facilité à danser sur la chanson (0 à 1)	Numérique (float)
duration_ms	Durée de la chanson en millisecondes	Numérique (int)
energy	Niveau d'énergie de la chanson (0 à 1)	Numérique (float)
instrumentalness	Probabilité que la chanson soit instrumentale (0 à 1)	Numérique (float)
key	Tonalité de la chanson (0 = Do, 1 = Do#, ..., 11 = Si)	Catégorielle (int)
liveness	Probabilité que la chanson ait été enregistrée en live (0 à 1)	Numérique (float)
loudness	Niveau sonore moyen en décibels (dB)	Numérique (float)
mode	Mode de la chanson (0 = mineur, 1 = majeur)	Catégorielle (int)
speechiness	Présence de paroles parlées dans la chanson (0 à 1)	Numérique (float)
tempo	Tempo de la chanson en battements par minute (BPM)	Numérique (float)
time_signature	Mesure rythmique de la chanson (ex : 3, 4, 5)	Catégorielle (int)
valence	Mesure de la positivité musicale (0 = triste, 1 = joyeux)	Numérique (float)
target	Popularité de la chanson (0 = impopulaire, 1 = populaire)	Catégorielle (int)
song_title	Titre de la chanson	Texte (string)
artist	Nom de l'artiste	Texte (string)

Aperçu global

2.1.1 Forme du Dataset

— Nombre de lignes : **2017**
— Nombre de colonnes : **16**

2.1.2 Valeurs Manquantes

Colonne	Manquantes
acousticness	0
danceability	0
duration_ms	0
energy	0
instrumentalness	0
key	0
liveness	0
loudness	0
mode	0
speechiness	0
tempo	0
time_signature	0
valence	0
target	0
song_title	0
artist	0

2.1.3 Types de Données

Colonne	Type
acousticness	float64
danceability	float64
duration_ms	int64
energy	float64
instrumentalness	float64
key	int64
liveness	float64
loudness	float64
mode	int64
speechiness	float64
tempo	float64
time_signature	int64
valence	float64
target	int64
song_title	object
artist	object

— **Aucune valeur manquante** : pas d'imputation nécessaire, ce qui simplifie le prétraitement.
— **Types cohérents** :
  — Variables numériques correctement typées (`float64`, `int64`) : prêtes pour l'analyse statistique et l'entraînement des modèles.
  — `song_title` et `artist` sont de type `object` (texte) : à exclure pour des modèles numériques classiques sauf si besoin d'encodage.
— **Colonnes spécifiques à vérifier** :
  — `key`, `mode`, `time_signature` sont des entiers discrets → potentiellement à convertir en variables **catégorielles** via encodage.

Table 2 – Statistiques descriptives des variables

Variable	min	max	std	mean
acousticness	0.000003	0.995	0.260	0.188
danceability	0.122	0.984	0.161	0.618
duration_ms	16042	1004627	81982	246306
energy	0.0148	0.998	0.210	0.682
instrumentalness	0.0	0.976	0.273	0.133
key	0.0	11.0	3.648	5.343
liveness	0.0188	0.969	0.155	0.191
loudness	-33.097	-0.307	3.762	-7.086
mode	0.0	1.0	0.487	0.612
speechiness	0.0231	0.816	0.090	0.093
tempo	47.859	219.331	26.686	121.603
time_signature	1.0	5.0	0.256	3.968
valence	0.0348	0.992	0.247	0.497
target	0.0	1.0	0.500	0.506

— **acousticness** : Moyenne faible (0.188), écart-type élevé (0.26), variation importante (min 0, max 1). → La majorité des morceaux ne sont pas acoustiques, mais quelques-uns le sont fortement.

— **danceability** : Moyenne relativement élevée (0.618), peu de morceaux très peu dansants (min = 0.122), certains très dansants (max = 0.984). → Dataset majoritairement orienté vers des morceaux rythmés.
— **duration_ms** : Moyenne d'environ 4 min (246 306 ms), mais grande variation (min 16 sec, max 16 min). → Présence de morceaux très courts ou très longs.
— **energy** : Moyenne élevée (0.682), la majorité des morceaux sont dynamiques. → Convient à des styles énergiques comme la pop ou l'électro.
— **instrumentalness** : Moyenne basse (0.133), mais avec max très élevé (0.976) → Principalement des morceaux avec voix, mais présence de quelques instrumentaux purs.
— **key** : Moyenne 5.3 (correspondant à Fa), std 3.6. → Répartition assez homogène des tonalités.
— **liveness** : Moyenne basse (0.191), max élevé (0.969) → Peu de morceaux enregistrés en live, mais certains le sont.
— **loudness** : Moyenne de -7.08 dB, ce qui est standard pour les morceaux modernes (forts mais pas écrêtés). Grande plage d'intensité sonore.
— **mode** : Moyenne 0.61 → La majorité des morceaux sont en mode majeur, souvent perçus comme plus "joyeux".
— **speechiness** : Moyenne très basse (0.093), mais max élevé (0.816) → La plupart des morceaux ne contiennent pas beaucoup de parole, mais certains peuvent être du type rap ou spoken word.
— **tempo** : Moyenne 121.6 BPM → Classique pour la musique pop/dance. Plage large (de 48 à 219 BPM), ce qui reflète une diversité de genres.
— **time_signature** : Moyenne proche de 4 → La grande majorité est en signature rythmique 4/4 (standard).
— **valence** : Moyenne de 0.497, std de 0.247 → Équilibre entre morceaux joyeux et tristes. Variabilité émotionnelle présente.
— **target** : Moyenne 0.506 → Classe cible presque parfaitement équilibrée (peut-être succès ou non ?).

Visualisations exploratoires

Distribution de la variable cible

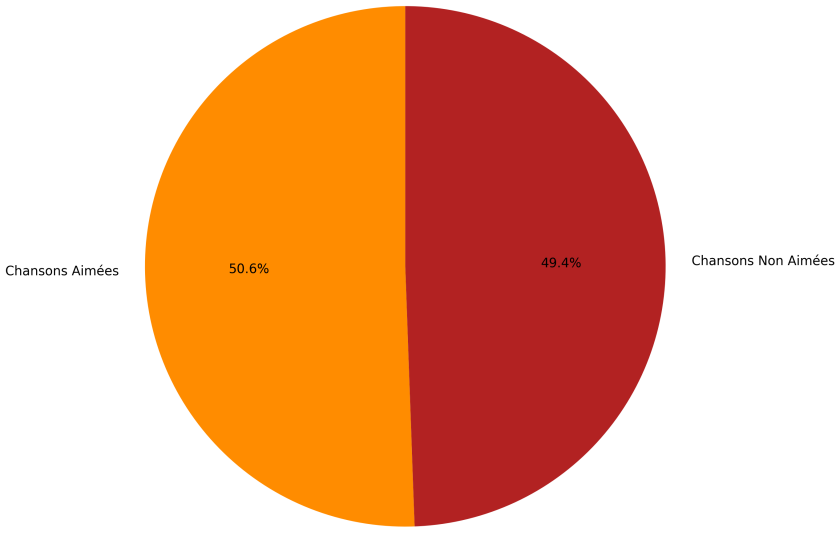


FIGURE 1 – Distribution de la variable target

La distribution est presque parfaitement équilibrée, avec une légère prépondérance de chansons aimées. Cette quasi-parité (**écart de seulement 1,2%**) indique :
— Un jeu de données bien **équilibré**, idéal pour l'entraînement d'algorithmes de machine learning
— **Absence de biais significatif** vers l'une ou l'autre catégorie

Pour un modèle de prédiction :

— Une distribution équilibrée permet d'obtenir des **résultats plus fiables**

— Les **métriques de performance** (comme l'accuracy) seront **plus représentatives**, car il n'y a pas de **classe dominante** qui fausse les prédictions

Heatmap des corrélations

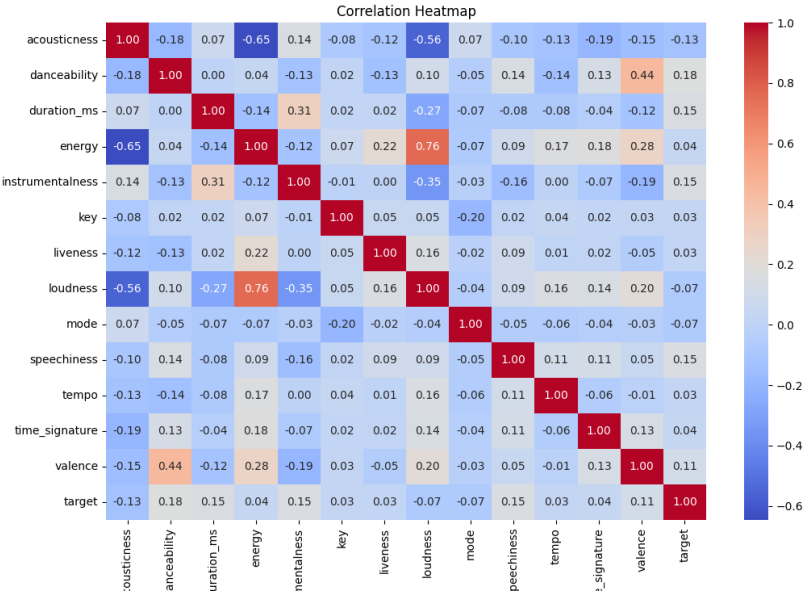


FIGURE 2 – Matrice de corrélation

3.2.1 Corrélations les plus fortes (positives)

Variables liées	**Corrélation**	**Interprétation**
energy & loudness	0.76	Plus une chanson est énergique, plus elle est forte (logique en audio).
valence & danceability	0.44	Les chansons "joyeuses" (valence) sont plus dansables.
instrumentalness & duration_ms	0.31	Les chansons plus longues ont tendance à être plus instrumentales.

3.2.2 Corrélations les plus fortes (négatives)

Variables liées	**Corrélation**	**Interprétation**
energy & acousticness	-0.65	Les morceaux acoustiques sont souvent moins "énergétiques".
loudness & acousticness	-0.56	Les morceaux acoustiques sont moins forts (en volume sonore).
loudness & instrumentalness	-0.35	Les morceaux instrumentaux sont souvent plus calmes.

3.2.3 Corrélation avec la variable "target"

Variable	Corrélation	Observation
danceability	0.18	Faible corrélation positive — les chansons dansables sont légèrement plus liées à la cible.
duration_ms / speechiness / instrumentalness	0.15	Corrélations faibles, mais positives.
acousticness / loudness / energy	< 0.1 ou négatif	Peu ou pas de lien significatif avec la cible.

Conclusions

- **Redondance possible** : **Energy** et **loudness** étant très corrélées (0.76), l'une pourrait être supprimée pour réduire la colinéarité dans un modèle de machine learning.
- **Relations logiques** : Les corrélations sont globalement **cohérentes**.
- **Prédiction de target** : La variable **target** n'est fortement corrélée à *aucune* caractéristique individuelle.

Pairplots

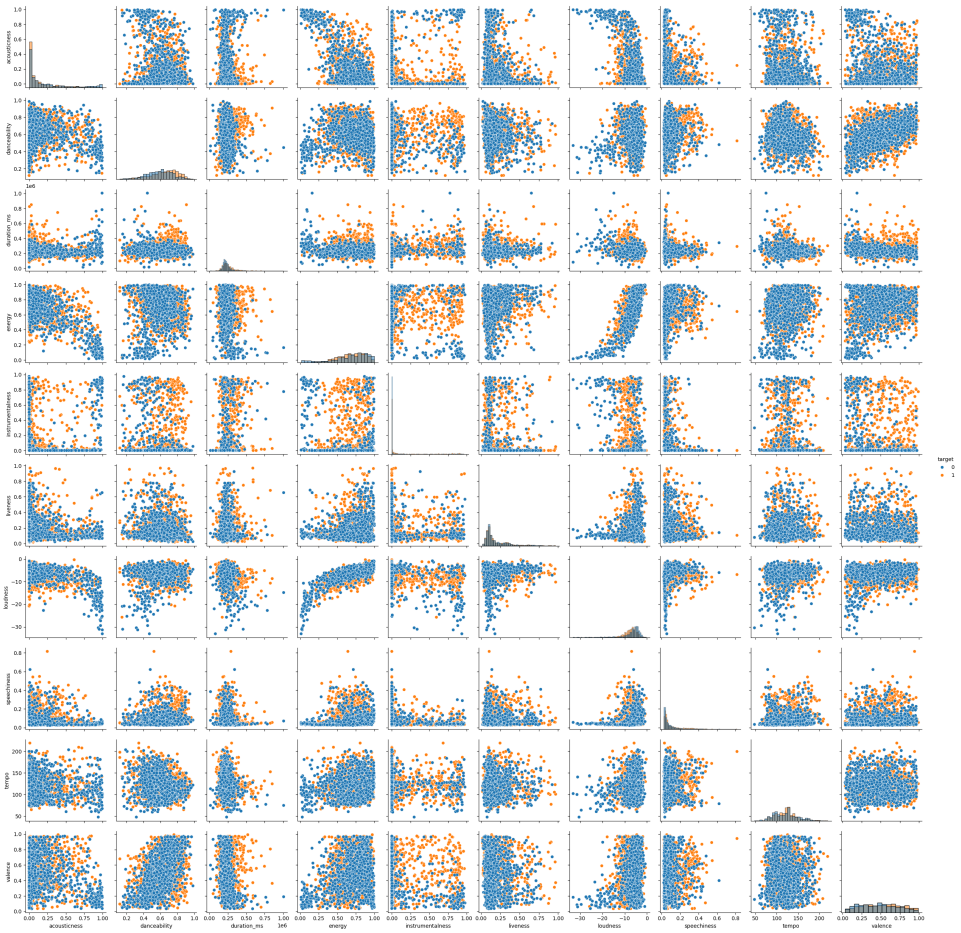


FIGURE 3 – Pairplot des variables

- **Variables discriminantes** : certaines variables montrent des différences marquées entre les classes (target = 0 et target = 1), notamment :
  - energy, loudness et instrumentalness (plus élevés pour la classe 1),
  - acousticness (plus élevé pour la classe 0),

  - valence (répartition différente entre les deux classes).
- **Corrélations importantes** :
  - Forte corrélation positive entre energy et loudness.
  - Corrélation négative entre acousticness et energy.
  - Cela indique une redondance potentielle qu'il conviendra de prendre en compte lors du choix des variables explicatives.
- **Variables moins pertinentes individuellement** :
  - tempo, speechiness, liveness et duration_ms montrent peu de variation entre les classes, ce qui limite leur pouvoir discriminant pris isolément.

Conclusion : L'analyse visuelle met en évidence plusieurs variables prometteuses pour la classification. Toutefois, en raison de corrélations fortes entre certaines d'entre elles, une étape de sélection ou de transformation s'avère nécessaire.

Histograms des attributs

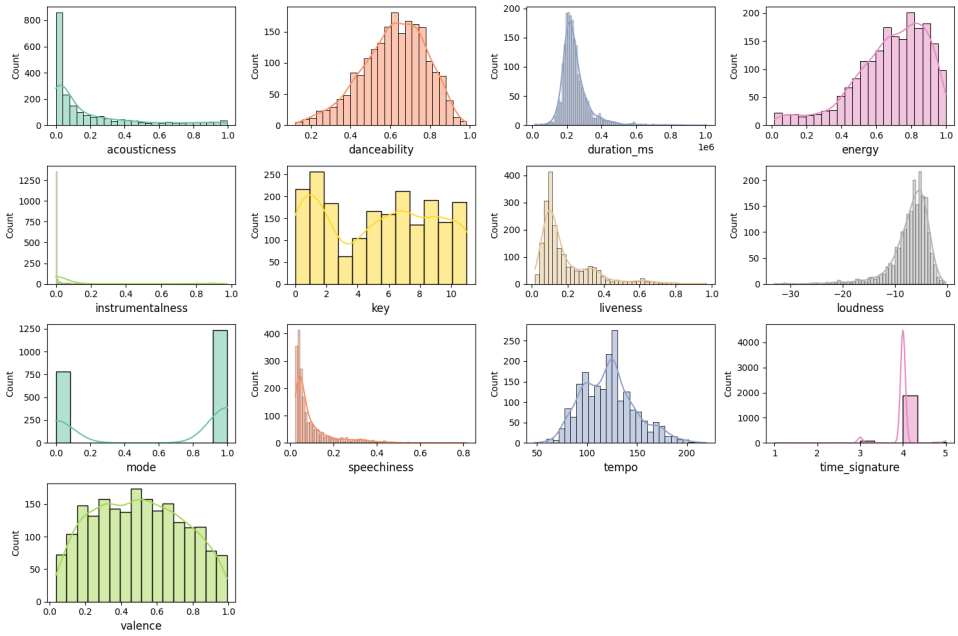


FIGURE 4 – Distribution des variables

Table 3 – Résumé des distributions des variables audio

Variable	Résumé des observations
acousticness	Distribution très asymétrique à droite (majorité proche de 0). La plupart des morceaux sont peu acoustiques.
danceability	Distribution centrée autour de 0.6, en forme de cloche. Semble relativement normale, bon candidat pour des modèles linéaires.
duration_ms	Distribution asymétrique à droite. La majorité des morceaux durent entre 2 et 4 minutes. Une transformation logarithmique peut être utile.
energy	Distribution asymétrique à gauche, concentrée entre 0.6 et 1. Beaucoup de morceaux énergétiques.
instrumentalness	Distribution fortement biaisée à gauche, pics extrêmes vers 0. Très peu de morceaux purement instrumentaux.
key	Distribution quasi-uniforme entre les 12 tonalités. Pas de tonalité dominante → à encoder via one-hot.
liveness	Distribution asymétrique à droite, majorité < 0.3. Peu de morceaux enregistrés en live.
loudness	Distribution centrée vers -5 dB, légèrement asymétrique à droite. Variation cohérente du volume sonore.
mode	Distribution bimodale forte (pics à 0 et 1). Variable binaire : mineur (0) / majeur (1).
speechiness	Distribution fortement biaisée à gauche. Très peu de morceaux avec un contenu très "parlé".
tempo	Distribution légèrement multimodale, avec un pic autour de 120 BPM. Typique des musiques dansantes ou pop.
time_signature	Distribution extrêmement concentrée sur 4. Peut être simplifiée (e.g., binaire : 4 vs. autres).
valence	Distribution quasi-uniforme. Répartition équilibrée entre morceaux joyeux et tristes.

Conclusion

- **Transformation** pour les variables très asymétriques : acousticness, instrumentalness, speechiness, liveness, duration_ms.
- **Variables à distribution proche normale** : danceability, loudness, tempo.
- **Variables catégorielles** à encoder : key → one-hot, mode → binaire, time_signature → peut être réduite.

Analyse des caractéristiques audio (en lien avec le target)

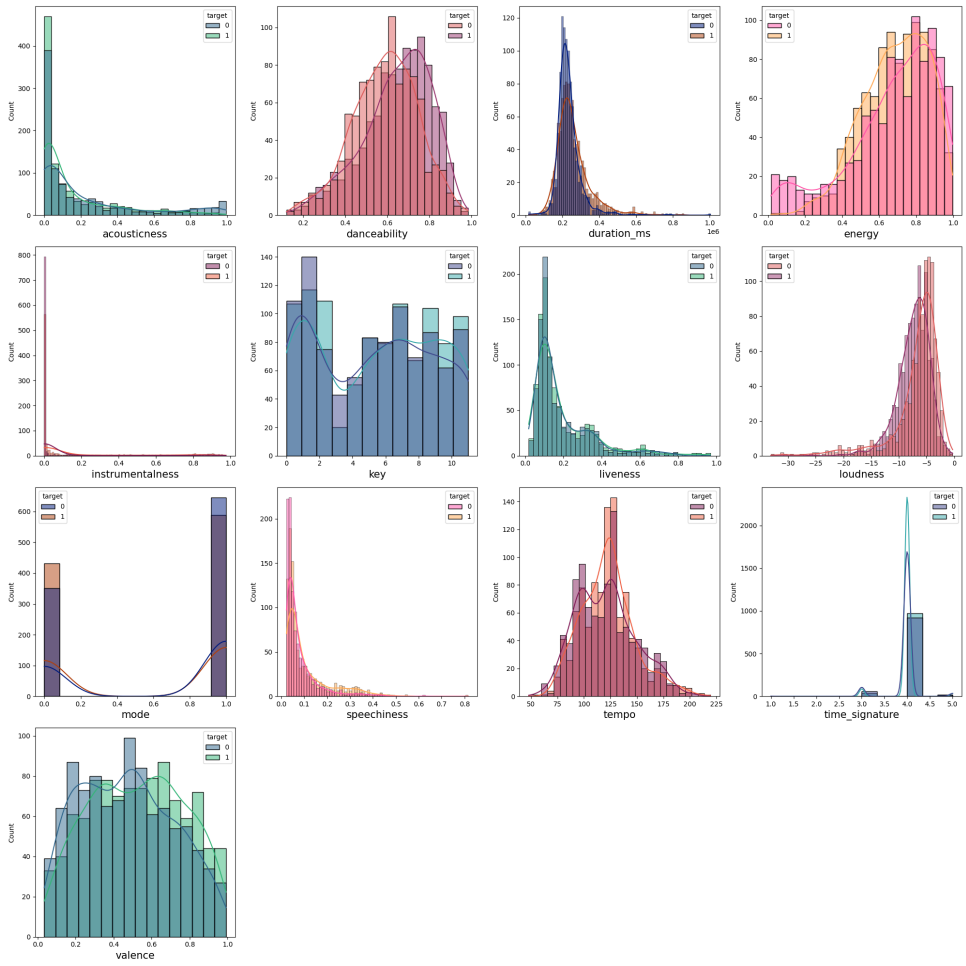


FIGURE 5 – Distribution des variables par classe target

Analyse des variables

Variables fortement asymétriques : `acousticness`, `instrumentalness`, `speechiness`

- Ces variables sont *fortement concentrées vers 0*, avec quelques valeurs très élevées.
- Elles peuvent être *binarisées* pour une meilleure lisibilité et interprétabilité :
  - `acousticness` $> 0.5 \rightarrow$ chanson acoustique.
  - `instrumentalness` $> 0.5 \rightarrow$ chanson sans voix.
  - `speechiness` $> 0.33 \rightarrow$ contenu parlé (rap, podcast...).
- Cela simplifie leur usage dans un modèle sans perte d'information significative.

Variables différenciantes utiles : `danceability`, `energy`, `loudness`, `valence` Ces variables montrent des *écarts clairs entre target = 0 et 1* :

- `Danceability` : les chansons aimées sont plus dansantes.
- `Energy` : elles sont plus énergiques (niveau d'intensité sonore élevé).
- `Loudness` : elles sont plus fortes en volume.
- `Valence` : les chansons aimées tendent à être plus positives (valence haute).

Elles peuvent être utilisées *telles quelles dans un modèle prédictif.*

Variables partiellement informatives : `tempo`, `duration_ms`, `liveness`

- `Tempo` : légère tendance à des BPM plus élevés pour les morceaux aimés, mais signal faible.
- `Duration_ms` : aucune différence claire ; à normaliser si utilisée.

— `Liveness` : utile uniquement dans les cas extrêmes (valeurs > 0.8).

Variables peu discriminantes : `key`, `mode`, `time_signature`
— `Key` : distribution relativement uniforme, sans impact clair.
— `Mode` : légère préférence pour le mode majeur (1) dans les chansons aimées.
— `Time_signature` : majorité en 4/4 pour tous les cas → peu utile seule.
Ces variables peuvent être *encodées* (one-hot ou binaire) si conservées.

Table 4 – Traitement recommandé des variables

Type	**Variables**	**Traitement**
Continues	danceability, energy, loudness, valence	Utilisation directe
Binarisées	acousticness, instrumentalness, speechiness	Seuils (> 0.5, > 0.33)
À évaluer	tempo, liveness	À normaliser ou transformer
Catégorielles	key, mode, time_signature	One-hot encoding ou binarisation simplifiée

Analyse statistique

Test du Chi² (vs target)

Table 5 – Résultats du test du Chi²

Variable	**p-value**
instrumentalness	7.23e-36
loudness	1.05e-25
artist	5.83e-24
danceability	4.30e-20
duration_ms	3.28e-16
speechiness	1.00e-09
tempo	2.68e-05
valence	8.88e-05
acousticness	2.22e-04
energy	7.11e-03

Conclusion 10 variables ont un lien significatif avec la cible → à conserver. Les autres peuvent être exclues pour simplifier le modèle.

ANOVA

Table 6 – Résultats de l'ANOVA - Variables significatifs

Variable	**F-statistique**	**p-value**	**Conclusion**
danceability	64.95	1.31e-15	Préférence nette pour les chansons plus dansantes.
speechiness	48.95	3.56e-12	Les chansons contenant davantage de paroles sont plus populaires.
instrumentalness	48.04	5.61e-12	Les chansons instrumentales présentent une différence marquée de popularité.
duration_ms	44.35	3.53e-11	Préférence pour des durées spécifiques.
acousticness	34.44	5.13e-09	Les morceaux plus acoustiques sont mieux perçus.

Conclusion Certaines variables musicales influencent significativement la popularité des chansons sur Spotify. Ces éléments peuvent guider l'optimisation de notre modèle de prédiction.

Préparation des données

Variables retenues

— **Variables numériques** : danceability, energy, loudness, speechiness, instrumentalness, duration_ms, acousticness, valence, tempo
— **Variables catégorielles** : key, mode, time_signature
— **Variable cible** : target

Normalisation

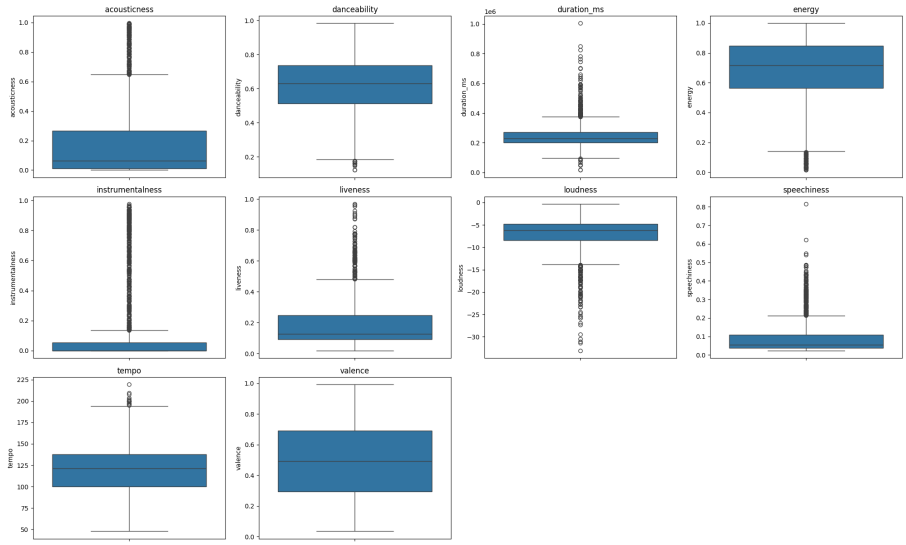


FIGURE 6 – Analyse des Distributions et des Outliers dans les attributs musicaux

L'analyse des boxplots montre que :
— Plusieurs variables comme `duration_ms`, `tempo`, `instrumentalness` ou `speechiness` présentent des *outliers notables* (morceaux très longs, très rapides ou très parlés).
— Les échelles des variables sont *hétérogènes* : `duration_ms` est en millisecondes, `loudness` est en décibels négatifs, tandis que d'autres variables comme `danceability`, `valence`, `energy` ou `acousticness` sont normalisées entre 0 et 1.
— Certaines distributions sont *asymétriques*, notamment `instrumentalness`, `speechiness` et `acousticness`, qui sont très concentrées vers 0 avec de rares valeurs élevées.

Afin de garantir une base propre pour la modélisation, les étapes suivantes seront abordées :
— *Transformation logarithmique* sur les variables à longue traîne (`instrumentalness`, `speechiness`, `tempo`, `duration_ms`) pour réduire l'asymétrie.
— *Mise à l'échelle des variables* :
  — **RobustScaler** est adapté pour limiter l'influence des outliers tout en normalisant les données.
  — Alternativement, **StandardScaler** peut être utilisé si les outliers sont filtrés.

Table 7 – Statistiques descriptives après normalisation

Variable	count	mean	std	min	25%	50%	75%	max
acousticness	2017.000	0.487	1.018	-0.248	-0.210	0.000	0.790	3.648
danceability	2017.000	4.23e-16	1.000	-3.084	-0.649	0.078	0.743	2.271
duration_ms	2017.000	0.242	1.166	-3.032	-0.416	0.000	0.584	11.027
energy	2017.000	0.682	0.210	0.015	0.563	0.715	0.846	0.998
instrumentalness	2017.000	2.467	5.059	-0.001	-0.001	0.000	0.999	18.073
key	2017.000	5.343	3.648	0.000	2.000	6.000	9.000	11.000
liveness	2017.000	0.191	0.155	0.019	0.092	0.127	0.247	0.969
loudness	2017.000	3.10e-16	1.000	-6.917	-0.348	0.223	0.622	1.802
mode	2017.000	0.612	0.487	0.000	0.000	1.000	1.000	1.000
speechiness	2017.000	0.536	1.276	-0.451	-0.247	0.000	0.753	10.796
tempo	2017.000	121.603	26.686	47.859	100.189	121.427	137.849	219.331
time_signature	2017.000	3.968	0.256	1.000	4.000	4.000	4.000	5.000
valence	2017.000	-1.27e-16	1.000	-1.869	-0.817	-0.019	0.786	2.004
target	2017.000	0.506	0.500	0.000	0.000	1.000	1.000	1.000

Après application des techniques de mise à l'échelle, les caractéristiques du dataset présentent les propriétés attendues en fonction du **scaler utilisé** :

5.3.1 Colonnes normalisées avec `StandardScaler`

Les colonnes `danceability`, `loudness` et `valence` ont été normalisées à l'aide de `StandardScaler`, ce qui a permis de :

— centrer les données autour de **zéro** (moyenne ≈ 0),

— obtenir une **variance unitaire** (écart-type ≈ 1).

Cela facilite les comparaisons entre variables et améliore les performances de nombreux algorithmes d'apprentissage automatique sensibles à l'échelle.

5.3.2 Colonnes transformées avec `RobustScaler`

Les colonnes `acousticness`, `duration_ms`, `instrumentalness` et `speechiness` ont été transformées via `RobustScaler`, adapté aux variables contenant des valeurs extrêmes. Cette technique :

— **centre les données autour de la médiane**,

— **réduit l'effet des outliers** sans contraindre la variance.

Cela se reflète dans des moyennes proches de zéro mais des écarts-types variables, comme pour `instrumentalness` (écart-type ≈ 5.06) et `duration_ms` (écart-type ≈ 1.16), indiquant une forte dispersion préservée.

Pour le prétraitement :

— *Transformation logarithmique* sur les variables à longue traîne (instrumentalness, speechiness, tempo, duration_ms) pour réduire l'asymétrie.

— *Mise à l'échelle des variables* :

  — RobustScaler est adapté pour limiter l'influence des outliers

  — StandardScaler peut être utilisé si les outliers sont filtrés

Encodage

TABLE 8 – Structure des données après encodage

Type de variables	Colonnes
Variables numériques originales	acousticness, danceability, duration_ms, energy, instrumentalness, liveness, loudness, speechiness, tempo, time_signature, valence
Variables textuelles	song_title, artist
Variable cible	target
Variables encodées (key)	key_0, key_1, key_2, key_3, key_4, key_5, key_6, key_7, key_8, key_9, key_10, key_11
Variables encodées (mode)	mode_0, mode_1

— **One-hot encoding pour 'key'** : La tonalité (0 à 11) a été transformée en 12 variables binaires
— **One-hot encoding pour 'mode'** : Le mode (mineur/majeur) a été transformé en 2 variables binaires
— Les variables numériques ont été conservées dans leur format d'origine après normalisation
— Les variables textuelles sont conservées pour référence mais ne seront pas utilisées dans les modèles
Cette structure de données est maintenant prête pour l'entraînement des modèles de machine learning.

Splitting

— **Données d'entraînement** : 75% du dataset
— **Données de test** : 25% du dataset
— **Stratification** : selon la variable cible pour maintenir la distribution

Modélisation et évaluation

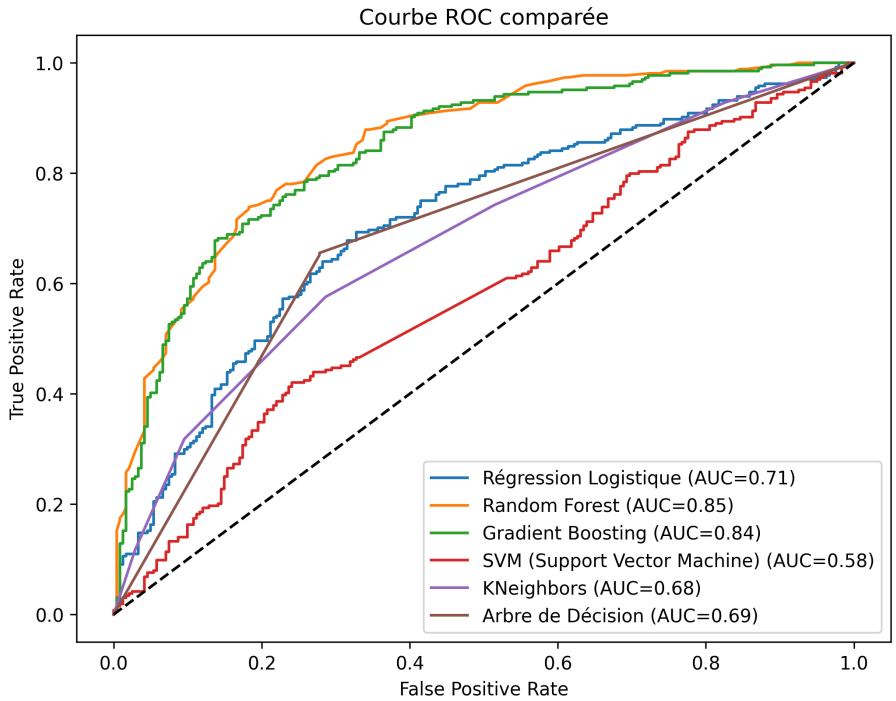


FIGURE 7 – Comparaison des modèles par courbe ROC

TABLE 9 – Performance des modèles

Modèle	**AUC**	**Commentaire**
Random Forest	0.85	Meilleur score, très bonne capacité de classement
Gradient Boosting	0.84	Excellente performance, proche de Random Forest
Régression Logistique	0.71	Moyenne, mais interprétable
KNeighbors	0.68	Modeste, sensible au choix de k
Arbre de Décision	0.69	Correct mais inférieur à Random Forest
SVM (linéaire)	0.58	Faible performance, proche du hasard

Conclusion : Les modèles *ensemble* (Random Forest et Gradient Boosting) offrent les *meilleurs résultats*.

Tuning

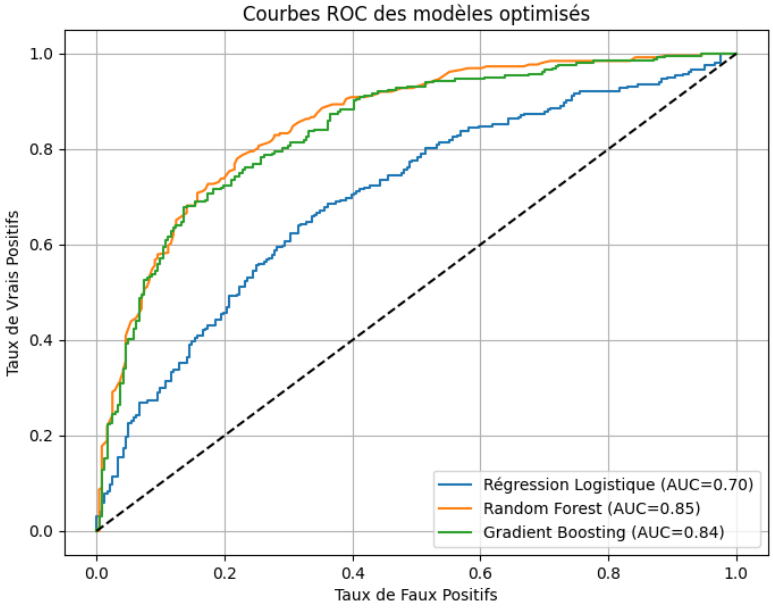


FIGURE 8 – Comparaison des modèles après tuning

Résultats après tuning

- *Régression Logistique* (C=0.01) : AUC = 0.701, précision = 66%. Modèle de base, interprétable mais limité.
- *Random Forest* (n_estimators=200) : meilleur résultat, AUC = **0.855**, précision = 78%.
- *Gradient Boosting* (learning_rate=0.1) : AUC = 0.842, précision = 76%, proche de la Random Forest.

Conclusion : La *Random Forest* est retenue comme modèle final pour ses performances supérieures après tuning.

Modèle final

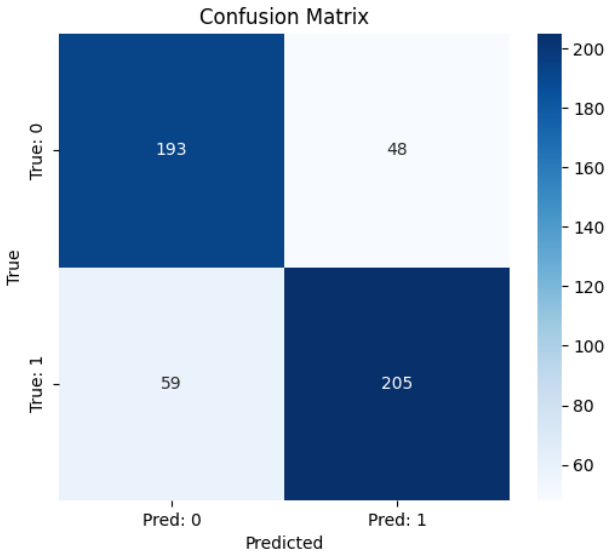


FIGURE 9 – Matrice de confusion du modèle final

Synthèse

L'analyse des attributs musicaux sur Spotify révèle que la popularité des chansons est principalement influencée par :

- **Instrumentalness** (p=7.23e-36) : les morceaux moins instrumentaux sont favorisés
- **Loudness** (p=1.05e-25) : volume sonore fortement corrélé au succès
- **Danceability** (p=4.30e-20) : préférence pour les chansons dansantes
- **Duration_ms** (p=3.28e-16) : impact significatif de la durée
- **Speechiness** (p=1.00e-09) : les chansons avec plus de paroles sont plus populaires

Le modèle Random Forest offre les meilleures performances prédictives (AUC=0.855, précision=78%), suivi par Gradient Boosting (AUC=0.842) et Régression Logistique (AUC=0.701).

Perspectives

Cette étude ouvre des pistes pour approfondir la compréhension des facteurs de succès musical. L'intégration d'autres variables contextuelles comme les tendances saisonnières, l'impact des réseaux sociaux ou les facteurs culturels pourrait enrichir le modèle prédictif.

Références

[1] Spotify API Documentation, *https ://developer.spotify.com/documentation/web-api/*

[2] Scikit-learn : Machine Learning in Python, *Journal of Machine Learning Research*

[3] Statistical Analysis of Music Features, *Journal of New Music Research*